

Arquitectura multiagente para la toma de decisiones en mercados de activos digitales

1. Contexto

Este trabajo se sitúa en el ámbito de la economía virtual de Counter-Strike 2 (CS2), un popular videojuego que cuenta con un ecosistema financiero integrado de alta frecuencia y liquidez.

Para entender este ecosistema, es fundamental definir los objetos o artículos que lo componen:

- **Skins:** Son artículos cosméticos que cambian la apariencia de elementos del juego como armas (rifles, pistolas), cuchillos, guantes y pegatinas (stickers).
- **Valor de los objetos:** Aunque no afectan al rendimiento del jugador, tienen un valor económico determinado por su rareza y el float (un valor numérico que indica el desgaste visual del artículo).
- **Mercado Virtual:** Estos objetos se compran y venden en diversas plataformas (Steam, Skinport, Buff), funcionando de manera idéntica a una bolsa de valores o un mercado de criptomonedas, con fluctuaciones constantes basadas en la oferta y la demanda.

Al existir esta fragmentación de mercados, el precio de un mismo artículo varía dependiendo del entorno, lo que genera constantes discrepancias de valor y oportunidades de arbitraje (es decir, comprar a menor precio en una plataforma para vender a mayor precio en otra).

2. Problema

A pesar de que el mercado de activos digitales de CS2 mueve cientos de millones anuales, carece de herramientas analíticas y de automatizaciones integradas o de libre uso. La motivación principal de este proyecto nace de esta profunda brecha tecnológica. Actualmente, la gestión de carteras en este entorno se realiza de forma manual o mediante herramientas estáticas, en nuestro caso usamos Excel para apuntar cada transacción, lo que resulta altamente ineficiente y riesgoso. Esta brecha tecnológica se ve agravada por los siguientes obstáculos técnicos y financieros:

- **Riesgo de exposición por fricción temporal (Trade Hold):** Los artículos adquiridos sufren un bloqueo de seguridad obligatorio de 7 días, lo que impide su transferencia inmediata. Esta restricción técnica genera un problema financiero crítico: el capital invertido queda inmovilizado, lo que imposibilita reaccionar ante caídas de precio a corto plazo y exige un nivel de planificación estratégica muy complejo de gestionar de forma manual.
- **Sobrecarga de información y fragmentación del mercado:** Monitorizar la evolución de cientos de activos de forma simultánea y de manera constante es inabarcable. La información está fragmentada en múltiples plataformas descentralizadas, cada una con sus propios precios, liquidez y volumen de ventas. Intentar procesar este gigantesco volumen de variables y métricas genera un cuello de botella analítico que impide identificar oportunidades de inversión óptimas de forma eficiente.

3. Propuesta del TFM

Para dar respuesta a las ineficiencias analíticas y a las barreras de liquidez descritas, este trabajo propone el diseño y desarrollo de una plataforma de simulación financiera sustentada en una arquitectura de sistemas multiagente.

El propósito principal de esta herramienta es evaluar si un ecosistema descentralizado de agentes de inteligencia artificial puede superar las limitaciones humanas y generar rendimientos estables en mercados de alta fricción. De forma específica, la plataforma permitirá:

- **Validar estrategias de inversión en un entorno seguro:** Simular operaciones sobre datos históricos para comprobar la viabilidad económica y la rentabilidad del modelo antes de exponer capital en el mercado abierto.
- **Automatizar la gestión del riesgo y del capital:** Coordinar de forma inteligente el presupuesto, distribuyéndolo entre distintas oportunidades para mitigar el impacto del capital inmovilizado por el trade hold.
- **Descentralizar el análisis de mercado:** Explotar la capacidad de los agentes colaborativos para monitorizar y gestionar compras y ventas de forma simultánea en múltiples plataformas, superando la sobrecarga de información.

4. Metodología y estructura del sistema

4.1. Diseño multiagente (MARL)

Se opta por una arquitectura multiagente para descentralizar la toma de decisiones y reducir la complejidad computacional del mercado. En lugar de un único modelo procesando miles de variables, el sistema se divide en una jerarquía de agentes especialistas que colaboran:

- **Especialización por entorno:** Se implementan agentes dedicados a plataformas específicas. Esto permite que cada unidad aprenda de forma independiente las dinámicas de liquidez, los tiempos de retiro y las estructuras de comisiones propias de cada mercado.
- **Jerarquía funcional y diversidad estratégica:** El sistema se organiza en tres niveles de actuación:
 - **Capa operativa (Estrategias de inversión):** Incluye agentes con distintos horizontes temporales para diversificar el riesgo: **Flippers** (corto plazo), **Swing traders** (medio plazo), **Inversores** (largo plazo) y **Arbitrajistas** (búsqueda de discrepancias de precios entre plataformas).
 - **Capa analítica (Contexto):** Agentes encargados de procesar la información cuantitativa del entorno. Mediante el análisis de datos tabulares (series temporales de precios, volumen y liquidez), identifican patrones numéricos, evalúan la tendencia global y emiten señales de rentabilidad.
 - **Capa de supervisión (Risk manager):** Un agente centralizador con visión total del saldo de la cartera que asigna el presupuesto optimizando la recompensa global.

4.2. Aprendizaje por Refuerzo (RL)

- **Por qué RL:** El trading es un proceso de decisión secuencial donde las acciones presentes afectan a las oportunidades futuras. El RL permite que los agentes aprendan mediante “ensayo y error” en el simulador.
- **Objetivo del aprendizaje:** Queremos que los agentes aprendan estrategias de inversión óptimas que maximicen el saldo total de la cartera. Un punto crítico es que aprendan a gestionar de forma autónoma el trade hold (bloqueo de 7 días), el sistema debe decidir matemáticamente cuándo “congelar” capital y cuándo esperar a una mejor oportunidad.

4.3. Predicción de precios

Es importante notar que el mercado de CS2 no incluye herramientas de predicción de precios, su mercado solo ofrece un registro histórico de ventas. Por ello, la plataforma introducirá su propio módulo de predicción:

- **Análisis predictivo de series temporales:** En lugar de depender de análisis visuales, el sistema utilizará modelos de aprendizaje profundo especializados en secuencias numéricas (como redes recurrentes o Transformers para series temporales). Estos modelos analizarán patrones en los históricos de precios, volúmenes de transacciones y niveles de desgaste (float) para anticipar movimientos futuros de forma autónoma, basándose estrictamente en la correlación de datos numéricos.

4.4. Arquitectura del sistema

La estructura se organiza en capas funcionales que orquestan el flujo de información:

1. **Capa de datos:** Encargada de la recolección de históricos de precios y la generación de imágenes para el análisis visual.
2. **Entorno de simulación:** El núcleo que replica fielmente las reglas de CS2, incluyendo las comisiones de cada plataforma y la restricción del trade hold.
3. **Capa de inteligencia:** Donde reside la jerarquía de agentes entrenando bajo el modelo MARL, fusionando señales visuales y numéricas para la toma de decisiones.
4. **Capa de evaluación:** Módulo de validación para medir el rendimiento económico (ganancias o pérdidas) en periodos de tiempo no vistos durante el entrenamiento.

5. Tecnología

La implementación técnica está diseñada para dar soporte directo a la arquitectura descrita anteriormente, utilizando el ecosistema de Python como eje central:

- **Inteligencia artificial (Capa de decisión):** Se emplearán librerías de vanguardia como PyTorch o TensorFlow para el desarrollo de los algoritmos de aprendizaje por refuerzo multiagente y los modelos predictivos sobre datos tabulares. Estas herramientas permiten gestionar la coordinación de la recompensa global entre los agentes operativos y supervisores.
- **Simulación y datos (Capa de datos y entorno):** Para la creación del simulador y el procesamiento de las series temporales, se utilizarán Pandas y NumPy, facilitando el cálculo de comisiones y la gestión del inventario bloqueado.
- **Integración y conexión:** La ingesta de datos desde plataformas externas (Steam, Skinport, Buff) se realizará mediante la integración de sus APIs y web scraping, y el procesamiento de archivos CSV/JSON, consolidando la información en estructuras de datos optimizadas para el entrenamiento.